电 子 科 技 大 学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

算法分析导论与实践挑战课程论文

论文题目	流行病动力学研究中的 计算机算法基本原理
作者姓名	周锐阳
学　　号	202321210211
授课教师	吴磊教授
学　　院	基础与前沿研究院
学科专业	计算机科学与技术

摘要

适当的数学模型可以准确地描述特定流行病的动态特性。本文旨在探索流行病学研究领域的新方法，将流行病学调查、微分方程模型和神经网络相结合，以更准确地预测和监测传染病的传播趋势。

本文建立了一个具有年龄结构和疫苗接种的 SEIRV 仓室模型和 LSTM 模型，并讨论了流行病学调查方法、微分方程模型以及神经网络在解决流行病动力学问题方面的应用。通过实际案例研究，验证了这种综合方法的有效性。

研究结果表明，将微分方程模型和神经网络相结合的方法在传染病建模中具有巨大潜力。这种综合性的方法能够更准确地捕捉传播动态并预测未来趋势，为应对传染病流行提供了有力的工具。

关键词： 传染病模型；流行病学调查；微分方程；神经网络；COVID-19

Abstract

Appropriate mathematical models can accurately describe the dynamic characteristics of specific epidemics. This paper aims to explore new approaches in epidemiological research by integrating epidemiological investigations, differential equation models, and neural networks to more accurately predict and monitor the transmission trends of infectious diseases.

In this paper, we establish an SEIRV model with age structure and vaccination and LSTM model. We also discuss the application of epidemiological investigation methods, differential equation models, and neural networks in addressing issues related to epidemiological dynamics. Through practical case studies, we validate the effectiveness of this integrated approach.

The research findings indicate that the combination of differential equation models and neural networks holds immense potential in infectious disease modeling. This approach can capture transmission dynamics more accurately and predict future trends, providing powerful tools for combating infectious disease outbreaks.

Keywords: Infectious Disease Modeling; Epidemiology; Differential Equations; Neural Networks; COVID-19

目录

摘要 . . . . . **i**
Abstract . . . . . **ii**
目录 . . . . . **iii**
第 1 章　绪论 **1**
1.1 研究背景与意义 1
1.2 国内外研究现状 1
1.3 主要工作 2
1.4 论文结构 2
第 2 章　仓室模型和神经网络模型的构建 **3**
2.1 具有年龄结构和疫苗接种的 SEIRV 仓室模型 3
2.2 LSTM 神经网络模型 4
第 3 章　综合流行病学调查、微分方程理论和神经网络模型的方法 **7**
3.1 数据驱动下的方法综合 7
3.2 流行病学调查 7
3.3 微分方程理论 7
3.4 神经网络模型 8
第 4 章　流行病学特征与模型训练结果 **9**
4.1 石家庄市疫情的流行病学特征 9
4.2 微分方程理论：平衡点的性质 10
4.3 神经网络模型：网络训练与预测 11

第 1 章　绪论

1.1　研究背景与意义

预防和治理传染病是一项关乎国家经济和人民健康的重要任务，量化研究疾病传播规律对于制定防控策略至关重要。传染病动力学利用疾病传播规律和外部因素构建数学模型，揭示疾病的演变过程，预测传播规律和趋势，并寻求最佳防控策略，为决策提供依据。流行病仓室模型从机制上解释了特定流行病区别于其他流行病的独特特征，能够很好地理解疾病的传播机制，预测疫情的发展趋势，评估控制措施的有效性。

自新冠肺炎首次出现以来，该疫情席卷全球，导致超过 7.6 亿例确诊病例和超过 690 万人死亡 [?]，深刻影响了世界的政治经济秩序，改变了普通人的生活。因此，研究新冠肺炎的动力学模型，以预测其传播趋势和制定最优控制策略，具有重要的理论和实践意义，有助于全球范围内的疫情防控工作。相比于其他传染病，COVID-19 具有许多独特的特征，如高度传染性、较长的潜伏期、相当比例的无症状患者、不断变异出新毒株、老年人群死亡率高等。因此，有必要针对 COVID-19 的特征开发具有针对性的数学模型，准确刻画 COVID-19 的动力学性质。这些结果能帮助政策制定者制定有效的策略，以减缓 COVID-19 的传播。

1.2　国内外研究现状

近年来，国内外研究集中关注以下主要问题：

- **概念综合** [? ? ? ? ? ? ?]：引入年龄结构、疫苗接种、人群流动、非药物干预措施（NPIs）等多种现实因素；
- **大规模数据驱动** [? ? ?]：大规模数据追踪人群行为、社交接触和病例报告，从而改进流行病预测和干预策略。
- **人工智能方法** [? ? ? ?]：通过人工智能方法分析大规模的流行病数据、改进预测和模拟的准确性，进一步挖掘流行病的隐藏的模式和关联。

其中，文献 [?] 提出了一种 SEIRV 仓室模型，该模型考虑了年龄结构和疫苗接种情况，特别关注了这些因素与宿主特性以及非药物干预（NPIs）之间复杂的相互作用。研究基于该模型，深入研究了中国河北省石家庄市农村地区 COVID-19 的流行病学和动力学特征。

近年来，有学者关注了 LSTM 模型在研究时间序列问题上的应用。文献 [?] 针对临床时间序列数据，采用了基于注意力机制的 LSTM 深度神经网络，摒弃了循环神经网络（RNN）的传统结构。作者提出了 SAnD（Simply Attend and Diagnose）架构，利用掩码自注意机制、位置编码和密集插值策略来处理时间顺序信息。此外，还开发了 SAnD 的多任务变体，用于同时处理多个诊断任务。文献 [?] 提出了一种 CF-LSTM 框架，用于解决复杂场景下的预测问题。文献 [?] 使用了 LSTM 网络构建一个能够在没有人工专家监督的情况下用于处理用户执行的一系列操作作为数据的模型。

文献 [?] 则开发了一种基于时间序列数据的混合 CNN-LSTM 模型，用于 COVID-19 确诊病例数量的预测。研究结果表明，将 CNN 和 LSTM 模型结合成 CNN-LSTM 编码器-解码

器结构，显著提高了预测性能。即使在数据量有限的情况下，该模型也能够产生令人满意的预测结果。

此外，文献 [?] 中将 2020 年 1 月 23 日前后的人口迁徙数据与最新的 COVID-19 流行病学数据整合到 SEIR 模型中。采用 2003 年 SARS 病毒的数据训练了一个 LSTM 模型。结果表明，动态 SEIR 模型在预测 COVID-19 疫情的高峰和规模方面非常有效。

文献 [?] 结合了神经网络模型和 SEIR 模型创建了一个混合模型。研究结果表明，混合模型在不同地理层次上改善了 SEIR 模型的性能，可以用于预测 ICU 的占用率，支持决策制定，例如病人转移和医疗人员以及呼吸机的调配等。

这些研究表明，多领域的探索和创新方法在应对 COVID-19 等流行病方面发挥着关键作用，为流行病学和公共卫生领域提供了宝贵的见解和工具。

1.3　主要工作

本文的主要工作集中在综合多种方法解决流行病学问题，即将流行病学调查、微分方程理论和神经网络模型相结合，以更好地理解和预测流行病的动态行为。论文详细探讨了流行病学调查的重要性，包括数据收集、验证模型预测和疫情追踪等方面，以提高流行病模型的准确性和适用性；微分方程理论在建立流行病模型、参数估计和稳定性分析中的关键作用，以及如何使用微分方程理论来分析模型的平衡点性质和阈值；最后，论述了神经网络模型在流行病学问题中的应用，包括非线性建模、数据驱动性和时间序列预测等方面，强调神经网络的优势和应用潜力。综合而言，本文通过整合不同领域的方法，为深入理解和有效应对流行病学问题提供了全面的方法框架和工具。

1.4　论文结构

在引言部分，强调了流行病学研究的重要性和挑战，明确了本研究的目标和主要贡献。在文献回顾中，深入探讨了流行病学调查方法、传染病建模技术以及神经网络在流行病学中的应用，为后续方法的提出提供了坚实的理论基础。在方法部分，详细描述了综合方法的设计，包括流行病学调查、微分方程模型和神经网络结合的具体步骤。随后，通过具体案例研究，将所提出的方法应用于实际流行病事件的分析，展示了方法的实际效果。结果和讨论部分呈现了案例研究的详细结果，对模型性能进行了评估，并探讨了方法的局限性和未来改进的潜力。

第 2 章　仓室模型和神经网络模型的构建

2.1　具有年龄结构和疫苗接种的 SEIRV 仓室模型

在 COVID-19 疫情暴发中，地区内的所有人分为五个仓室：易感者 $S(t)$，潜伏者 $E(t)$，感染者 $I(t)$，康复者 $R(t)$ 和接种疫苗者 $V(t)$。模型中的潜伏者包括被感染但由于病毒负载低而难以向其他个体传播的个体，而感染者指能向其他个体传播病毒的个体。模型进一步假设，G1 代表 60 岁以下的个体，G2 表示 60 岁及以上的个体。显然，G2 在 COVID-19 传播过程中面临着高风险，因为 G2 中患有高血压、糖尿病、高脂血症、心脏病、慢性炎症等基础疾病的人数较多。因为不同年龄组和性别组的疫苗接种情况存在差异，所以模型还考虑了接种疫苗者的情况。

该年龄结构仓室模型如下所示：

$$
\begin{aligned}
\dot{S}_1 &= \Lambda - (\beta_{11}I_1 + \beta_{12}I_2)\frac{S_1}{N} - (\nu_1 + \mu_1 + g)S_1, \\
\dot{S}_2 &= gS_1 - (\beta_{21}I_1 + \beta_{22}I_2)\frac{S_2}{N} - (\nu_2 + \mu_2)\,S_2, \\
\dot{E}_1 &= (\beta_{11}I_1 + \beta_{12}I_2)\frac{S_1}{N} - (\alpha_1 + \mu_1 + g)\,E_1, \\
\dot{E}_2 &= gE_1 + (\beta_{21}I_1 + \beta_{22}I_2)\frac{S_2}{N} - (\alpha_2 + \mu_2)\,E_2, \\
\dot{I}_1 &= \alpha_1 E_1 - (\gamma_1 + d_1 + \mu_1 + g)\,I_1, \\
\dot{I}_2 &= gI_1 + \alpha_2 E_2 - (\gamma_2 + d_2 + \mu_2)\,I_2, \\
\dot{R}_1 &= \gamma_1 I_1 - (\mu_1 + g)\,R_1, \\
\dot{R}_2 &= gR_1 + \gamma_2 I_2 - \mu_2 R_2, \\
\dot{V}_1 &= \nu_1 S_1 - (\mu_1 + g)\,V_1, \\
\dot{V}_2 &= gV_1 + \nu_2 S_2 - \mu_2 V_2.
\end{aligned}
\tag{2.1}
$$

模型中的所有参数均假定为常数，参数的描述如表 2.1所示。

表 2.1: 模型的参数及其描述

参数	含义	单位[f]	值	范围	来源
ΔT	失觉期	d	21	(17, 23)	[? ? ?]
N	石家庄市总人口	万	1900[c]	1900	[?]
Λ	每日新增人口的比率	d^{-1}	300.82	1000[d]	[?]
g	G1[a] 到 G2[b] 的衰老速率	d^{-1}	1.36×10^{-5}[e]	4×10^{-4}	[?]
β_{11}	I_1 引发的感染率[a]	$\mathrm{p}^{-1}\mathrm{d}^{-1}$	0.1790	(0, 0.5)	[?]
β_{12}	I_2 引发的感染率[a]	$\mathrm{p}^{-1}\mathrm{d}^{-1}$	0.1721	(0, 0.5)	[?]
β_{21}	I_1 引发的感染率[b]	$\mathrm{p}^{-1}\mathrm{d}^{-1}$	0.2833	(0, 0.5)	[?]
β_{22}	I_2 引发的感染率[b]	$\mathrm{p}^{-1}\mathrm{d}^{-1}$	0.2479	(0, 0.5)	[?]
$1/\alpha_1$	平均潜伏期[a]	d	5	(3.53, 6.6)	[? ? ?]
$1/\alpha_2$	平均潜伏期[b]	d	3	(3.53, 6.6)	[? ? ?]
$1/\gamma_1$	平均康复期[a]	d	28	(13.6, 33.4)	[? ?]
$1/\gamma_2$	平均康复期[b]	d	35	(13.6, 33.4)	[? ?]
ν_1	接种率[a]	d^{-1}	0	0	[?]
ν_2	接种率[b]	d^{-1}	0	0	[?]
d_1	SARS-CoV-2 导致的死亡率[a]	d^{-1}	2.37×10^{-7}	$(1, 3) \times 10^{-7}$	[? ? ? ? ?]
d_2	SARS-CoV-2 导致的死亡率[b]	d^{-1}	1.42×10^{-7}	$(1, 4) \times 10^{-7}$	[? ? ? ? ?]
μ_1	自然死亡率[a]	d^{-1}	2.37×10^{-7}	2.37×10^{-7}	[?]
μ_2	自然死亡率[b]	d^{-1}	1.42×10^{-7}	1.42×10^{-7}	[?]
p	老龄化率[b]	-	19.38%	19.38%	[?]

[a] G1 表示 60 岁以下的年龄组；
[b] G2 表示 60 岁及以上的年龄组；
[c] 石家庄市在 COVID-19 疫情期间的人口规模是 1900 万人；
[d] 每年新增 1000 万人除以 365 天等于每天新增 300.82 万人；
[e] 每年的衰老速率 4×10^{-4} 除以 365 天等于每天的衰老速率 1.36×10^{-5}；
[f] d 表示天，d^{-1} 表示每天，$\mathrm{p}^{-1}\mathrm{d}^{-1}$ 表示每人每天。

2.2　LSTM 神经网络模型

研究传染病流行的流行病学问题通常需要采用时间序列分析方法，这类方法基于对系统观察获得的数据进行建模和分析，以预测未来的传播趋势。其中，一种强大的工具是深度学习中的长短时记忆网络（LSTM，Long Short-Term Memory），该网络已被广泛用于处理和预测各种时间序列问题，包括流行病学数据的分析 [? ? ?]。

由 Hochreiter 和 Schmidhuber （1997）提出的 LSTM（Long Short-Term Memory）网络广泛用于解决具有长期相关特征的时间序列问题。LSTM 网络是一种循环神经网络（Recurrent Neural Network，RNN）的变体，设计用来解决传统 RNN 存在的长期依赖问题。LSTM 引入

了门控机制，能够更好地捕捉和管理序列数据中的长期依赖关系。

该模型的内部结构如图 2.1所示。

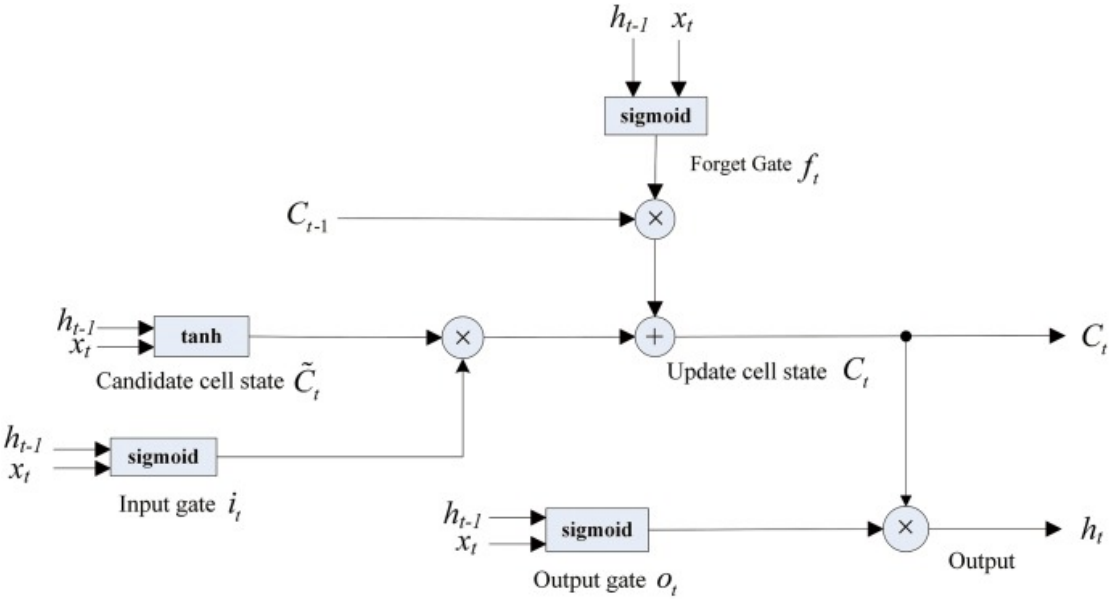

图 2.1: LSTM 模型的内部结构

该模型可用方程 (2.2)表示。

$$\begin{cases} f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right) \\ i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] + b_i\right) \\ \widetilde{C_t} = \tanh\left(W_C \cdot [h_{t-1}, x_t] + b_C\right) \\ C_t = f_t * C_{t-1} + i_t * \widetilde{C_t} \\ o_t = \sigma\left(W_o \cdot [h_{t-1}, x_t] + b_o\right) \\ h_t = o_t * \tanh\left(C_t\right) \end{cases} \tag{2.2}$$

方程 (2.2)包括以下主要组成部分：

1. 输入门（Input Gate）：

输入门决定哪些信息将被存储到细胞状态（cell state）中。它由以下几个步骤组成：

a. 计算遗忘门（Forget Gate）：通过 $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$ 计算遗忘门的值，它决定了以前的细胞状态中哪些信息要被遗忘。其中，W_f 是遗忘门的权重矩阵，h_{t-1} 是上一个时间步的隐藏状态，x_t 是当前时间步的输入，b_f 是偏置项，σ 是 sigmoid 激活函数。

b. 计算输入门的值（Input Gate）：输入门决定哪些新的信息将被添加到细胞状态中，即 $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$。

c. 计算候选细胞状态（Candidate Cell State）：计算一个候选的新细胞状态 $\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$。

2. 更新细胞状态：使用遗忘门、输入门以及候选细胞状态来更新细胞状态：$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$。

3. 输出门（Output Gate）：输出门决定哪些信息将被输出到隐藏状态以及最终的预测中。计算输出门的值 $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$。

4. 隐藏状态更新：使用输出门和细胞状态来更新当前时间步的隐藏状态：$h_t = o_t \cdot \tanh(C_t)$。

这些方程描述了 LSTM 模型的基本运算过程。LSTM 通过门控机制，能够选择性地遗忘、存储和输出信息，从而更好地处理长序列依赖关系，适用于各种序列建模任务，如自然语言处理、时间序列预测等。这些门控机制允许 LSTM 模型有效地学习和记忆序列中的重要信息。

本研究将基于莆田市的 COVID-19 感染数据，借助 SEIRV 传染病模型，通过调整传播概率、潜伏期、康复或死亡概率以及接触人数等参数，构建一个基本的训练数据集。此后，利用 LSTM 时间序列模型，结合仓室模型的基础，来研究病毒传播趋势，并进行石家庄市 COVID-19 传播的预测。这种结合深度学习和传染病建模的方法有望提供更准确的流行病学预测和决策支持。

第 3 章　综合流行病学调查、微分方程理论和神经网络模型的方法

3.1　数据驱动下的方法综合

本节讨论了在数据驱动下的综合方法，以解决流行病学问题。主要涵盖了以下三个关键方面：

流行病学调查方法强调了数据的重要性，包括收集各种数据，如病例报告、感染人群的特征和传播时间线等。这些数据用于描述流行病学特征、验证模型预测以及追踪疫情的变化。

微分方程理论在理解流行病的机制中起到关键作用。微分方程被用来建立流行病模型，描述疫情的动态行为。微分方程理论用于确定模型的平衡点性质，包括无病平衡点和地方病平衡点，以及阈值，如基本再生数等。

神经网络可以被引入以处理流行病学问题。神经网络具有非线性建模能力、数据驱动性以及在预测性能方面的优势。神经网络能够处理非线性效应，从数据中学习潜在模式，并用于预测流行病发展趋势。

3.2　流行病学调查

流行病学调查是流行病学研究的关键组成部分。数据收集是流行病学调查的基础，各种数据，如病例报告、感染人群的特征以及疫情传播的时间线，都必不可少。通过描述流行病学特征，以了解感染的地理分布、感染人群的年龄、性别和健康状况等信息，这些信息对于调整模型结构和进行参数估计非常重要。验证模型预测是确保流行病模型准确性和适用性的关键步骤，通过比较模型的预测与实际疫情发展趋势，评估模型的性能。流行病学调查还包括追踪疫情的变化，这包括监测新变种的出现和传播，以及疫情的季节性变化等，这些信息对于制定干预策略和应对流行病的挑战至关重要。

3.3　微分方程理论

微分方程被用来建立流行病学模型，描述疫情的动态行为。这些微分方程基于已知的流行病学参数和初始条件，描述了感染病例、康复病例、潜伏期病例等之间的关系。通过建立模型，研究人员可以更好地理解流行病学过程，预测疫情的发展趋势。

微分方程模型允许研究人员估计模型中的参数，例如感染率、康复率、潜伏期等。这些参数估计通常通过将模型的预测与实际观测数据进行拟合来获得。参数估计的准确性对于模型的可信度和适用性至关重要，因为它们反映了疫情的真实情况。

微分方程理论还用于分析模型的稳定性。这包括确定模型解是否会趋于稳定状态，这对于预测疫情的最终结果非常重要。通过分析平衡点的性质，包括存在唯一性、局部稳定性、全局稳定性和绝灭性等方面，可以评估模型的稳定性。

3.4　神经网络模型

神经网络模型在流行病学中具有重要作用，它能够进行非线性建模，有效捕捉复杂的流行病学动态，特别适用于模拟实际疫情中的非线性效应。神经网络也是数据驱动的工具，可以从大规模流行病学数据集中学习潜在的模式和关联性，为深入了解流行病提供强有力的支持。神经网络在时间序列预测和趋势分析方面表现出色，可用于准确预测未来的流行病发展趋势。综合这些优势，神经网络模型为深入理解和有效应对流行病学问题提供了一种强大的工具。

受第 1中已有模型的启发，本文构建的 LSTM 模型结构如下：

```
Model(
    (lstm): LSTM(8, 32, batch_first=True)
    (fc_1): Linear(in_features=32, out_features=128, bias=True)
    (fc_2): Sigmoid()
    (fc_3): Tanh()
    (fc): Linear(in_features=128, out_features=2, bias=True)
    (relu): ReLU()
)
```

为了评估预测值与实际值之间的差异，找出梯度下降方向以减小间隙，根据以下方程，将该模型的损失函数设置为均方误差 (MSE) :

$$\text{MSE} = \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{n}$$

设置 LSTM 模型使用 Adam 优化器、学习率设置为 0.001、损失函数采用均方误差函数（MSE）、使用随机梯度下降法进行训练，并进行 200 次迭代。

第 4 章　流行病学特征与模型训练结果

4.1　石家庄市疫情的流行病学特征

根据河北省卫生健康委员会的官方通报 [?]，新一轮石家庄市 COVID-19 疫情的第一个有症状病例报告于 2021 年 1 月 2 日，截止至 1 月 11 日，累计报告 513 例病例中包含 290 例有症状病例和 223 例无症状病例。因此，石家庄市政府采取了封闭村庄和异地隔离等措施，以迅速控制 COVID-19 的传播。

河北省卫生健康委员会报告的所有有症状病例的地点和年龄分布 [?]。1 月 2 日至 2 月 3 日的每日分布情况如图 4.1a所示。性别-年龄的分布如图 4.1b所示，并且按年龄组的分布如图 4.1c所示，其中 60 岁及以上的 868 例有症状病例所占的百分比为 25.81%。

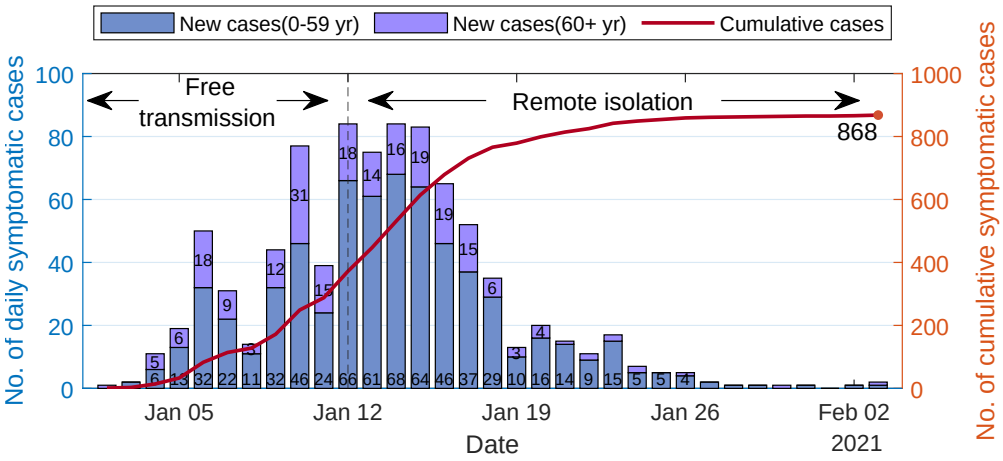

(a) 病例按报告日期的分布

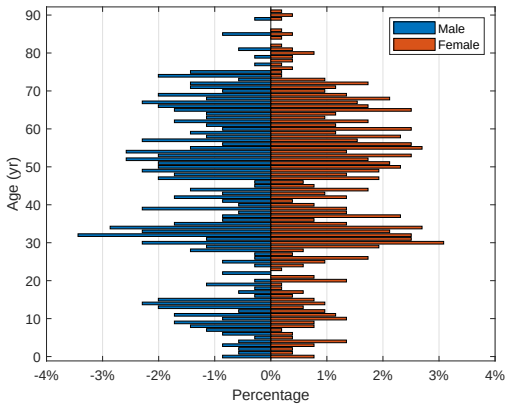

(b) 病例按性别—年龄的分布

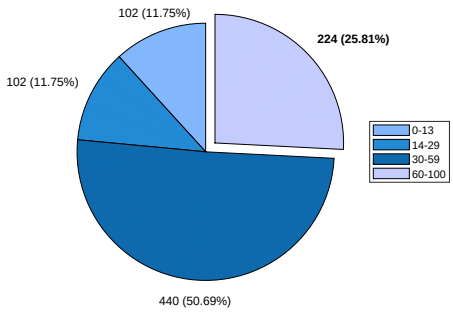

(c) 病例按年龄组的分布

图 4.1: 所有的有症状病例按报告日期、性别—年龄和年龄组的分布情况

4.2　微分方程理论：平衡点的性质

4.2.1　无病平衡点与稳定性分析

在传染病动力学中，无病平衡点是指在人群中没有任何感染的状态下，传染病的传播达到的一个平衡状态。

定理 1 (无病平衡点的存在唯一性)**.** 模型 (2.1)的无病平衡点 X^0 存在且唯一，其值为:

$$
\begin{aligned}
S_1^0 &= \frac{\Lambda}{\nu_1+\mu_1+g},\\
S_2^0 &= \frac{g}{\nu_2+\mu_2}S_1^0,\\
V_1^0 &= \frac{\Lambda\,\nu_1}{(\mu_1+g)\,(\nu_1+\mu_1+g)},\\
V_2^0 &= \frac{g\,(g\,\nu_2+\nu_2\,\mu_1+\nu_1\,\mu_2+\nu_1\,\nu_2)}{\nu_1\mu_2\,(\nu_2+\mu_2)}V_1^0.
\end{aligned}
$$

定理 2 (无病平衡点的全局稳定性)**.** 假设下列条件成立时,

$$
\begin{aligned}
&A_1D_1-B_{11}C_1>0,\quad A_2D_2-B_{22}C_2>0,\\
&-A_1A_2D_1D_2+(B_{11}B_{22}-B_{12}B_{21})\,C_1C_2>0.
\end{aligned}
$$

则无病平衡点 X^0 是全局渐近稳定的。

4.2.2　地方病平衡点与稳定性分析

传染病动力学中，地方病平衡点是指在特定的地区和特定的时间内，一个传染病的感染人口数量不再上升或下降，而是保持在一个稳定的水平上。在这种情况下，疾病传播呈现出一种平衡状态，称为地方病平衡点。

定理 3 (地方病平衡点的存在性和唯一性)**.** 如果以下条件之一成立,

条件 i. $a_{11}\neq 0,\ b_{11}\neq 0,$

$$
\begin{aligned}
&a_{11}\,(a_1b_{12}-a_{12}b_1)^2=2a_2\,(a_{11}b_{12}-a_{12}b_{11})\,(a_1b_{11}-a_{11}b_1)\,,\\
&b_{11}\,(a_1b_{12}-a_{12}b_1)^2\\
&=b_{22}\,(a_1b_{11}-a_{11}b_1)^2+2b_2\,(a_1b_{12}-a_{12}b_1)\,(a_1b_{11}-a_{11}b_1)\,;
\end{aligned}
$$

条件 ii. $a_{11}=0,\ b_{11}\neq 0,\ a_{12}b_{12}\neq 0,$

$$
\begin{aligned}
&(a_{12}b_1+a_1b_{12}-a_2b_{11})^2-4a_{12}b_{12}a_1b_1=0,\\
&\quad -{b_{12}}^2\,(a_2\,b_{11}-a_1\,b_{12}+a_{12}\,b_1)^2/\,[b_{11}(a_1\,b_{12}-a_2\,b_{11}+a_{12}\,b_1)]\\
&=4\,a_{12}\,b_2\,b_{12}-a_1\,b_{12}\,b_{22}+a_2\,b_{11}\,b_{22}-a_{12}\,b_1\,b_{22};
\end{aligned}
$$

条件 iii. $a_{11}=0,\ b_{11}\neq 0,\ a_{12}b_{12}=0,$

$$
\begin{aligned}
&b_{11}\left(b_{22}\,{a_1}^2\,b_1+2\,a_2\,b_2\,b_{11}\,a_1+2\,a_2\,a_{12}\,{b_1}^2\right)\\
&=2a_1b_2b_{11}(\ b_{12}\,a_1+\ a_{12}\,b_1)+{a_2}^2\,b_1\,{b_{11}}^2+{a_{12}}^2\,{b_1}^3;
\end{aligned}
$$

条件 iv. $a_{11} \neq 0,\ b_{11} = 0,\ a_{11}b_{22} - 2a_{12}b_{12} \neq 0,$

$$
\begin{aligned}
&\left({a_{12}}^2\, b_1 - a_1\, a_{12}\, b_{12} - a_{11}\, a_{12}\, b_2 + a_1\, a_{11}\, b_{22}\right)^2 \\
&+ 2\, a_2\, a_{11}\, (2\, a_{12}\, b_{12} - a_{11}\, b_{22})\, (a_1\, b_{12} - a_{11}\, b_2 + a_{12}\, b_1) = 0, \\
&(a_{11}b_2 - a_1b_{12} - a_{12}b_1)^2 + 2a_1b_1(a_{11}b_{22} - 2a_{12}b_{12}) = 0;
\end{aligned}
$$

那么模型 (2.1) 存在一个唯一的地方病平衡点 X^*.

定理 4 (地方病平衡点的全局稳定性)**.** 假设下列条件成立时,

$$
\begin{aligned}
&m_{12}m_{13}m_{21}m_{44} - m_{11}m_{14}m_{22}m_{53} > 0, \\
&m_{11}m_{22} - m_{12}m_{21} > 0, \\
&m_{13}m_{44} - m_{14}m_{53} > 0, \\
&m_{33}m_{44} - m_{11}m_{53} > 0.
\end{aligned}
$$

则地方病平衡点 X^* 是全局渐近稳定的。

4.3　神经网络模型：网络训练与预测

本节将详细介绍使用 LSTM 网络模型来预测 COVID-19 的动力学特征的过程。

基于莆田市的 COVID-19 感染数据，借助 SEIRV 传染病模型，通过调整传播概率、潜伏期、康复或死亡概率以及接触人数等参数，进行 200 轮的训练。可以观察到损失在经过 100 轮训练后趋近于零，表明模型已经取得了良好的收敛性能，如图 4.2所示。

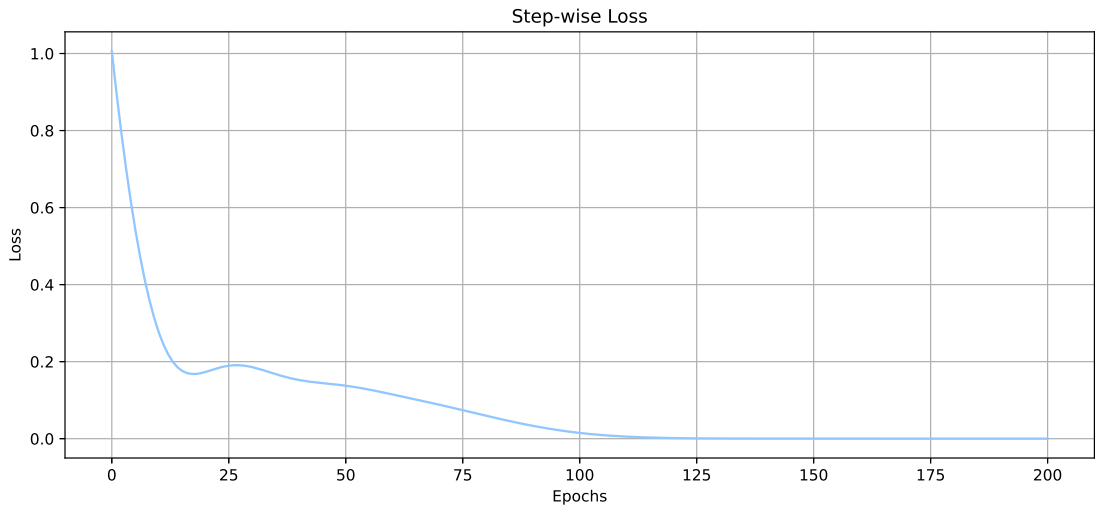

图 4.2: 损失函数随训练轮数的变化。蓝色曲线代表平滑后的实际确诊病例总数，而红色曲线代表神经网络模型所预测的确诊病例总数。实线代表 G1，而虚线代表 G2。

同时，在图 4.3中给出训练结果和实际结果的比较。

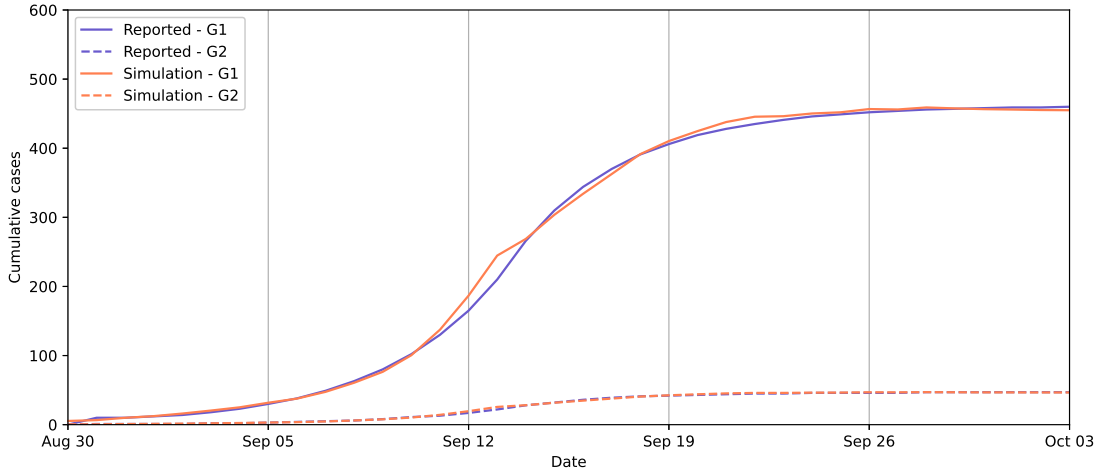

图 4.3: 莆田市疫情的流行规模

利用以上训练好的模型，对石家庄市的疫情流行规模进行预测。在图4.4中展示了石家庄市疫情的流行规模。

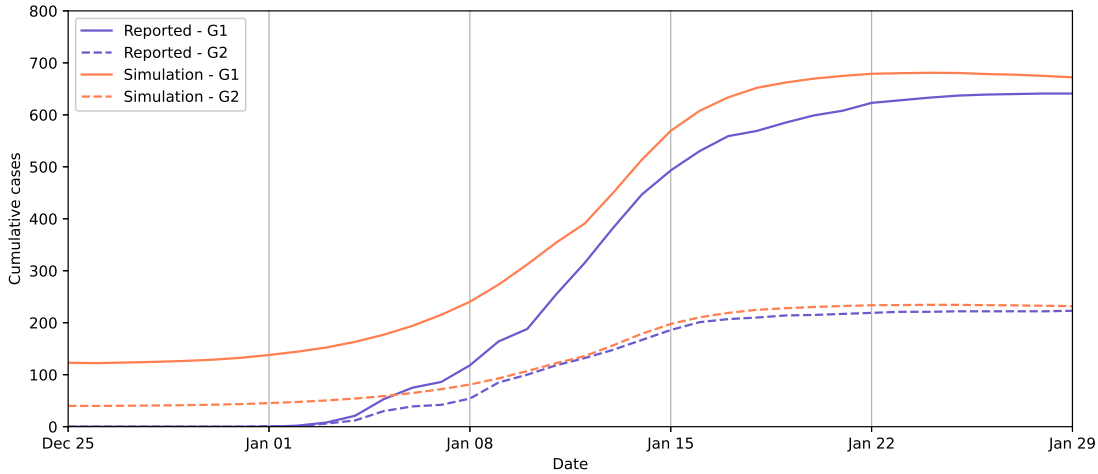

图 4.4: 石家庄市疫情的流行规模

选了好的神经网络模型在石家庄市的疫情中表现出了以下几个关键特征：

- 正确识别出了流行中存在的失觉期；
- 正确识别出了流行中存在的拐点；
- 神经网络所预测的最终规模和实际规模相仿。

这些结果表明，LSTM 网络模型在 COVID-19 疫情预测方面表现出了良好的准确性和鲁棒性，为疫情监测和决策提供了有力的工具。

讨 论

研究流行病学仓室模型时，流行病学调查、微分方程方法和神经网络方法是三种相互关联且互补的工具。首先，流行病学调查在这个过程中扮演着基础性的角色。它提供了必要的数据基础，这些数据可以用来校准模型参数，验证模型的预测，以及作为输入数据供模型使用。流行病学调查的数据不仅丰富，而且具有真实世界的背景，使得模型更有实际意义。

与此同时，微分方程方法和神经网络方法相互互补，对流行病学仓室模型的研究提供了不同的视角。微分方程方法建立在流行病学原理之上，提供了基于传统流行病学知识的模型。这些模型能够捕捉疾病传播的动态变化，为疾病传播的数学建模提供了强大的工具。另一方面，神经网络方法处理复杂的非线性关系，特别适用于疾病传播过程中的随机性和复杂性。神经网络可以通过学习数据中的模式和趋势来改进模型的预测性能，尤其在考虑到多种因素时，其表现出色。

将这些方法综合使用，有助于提高对流行病学过程的理解和预测能力。这不仅有助于更好地理解疾病的传播方式和趋势，还能为公共卫生政策制定和干预措施的制定提供更有根据的指导。通过综合运用这些工具，可以更有效地应对流行病威胁，保护公众健康。

创新点

本文建立了一个 SEIRV 仓室模型，该模型考虑了年龄结构和疫苗接种，并应用于分析 2021 年初石家庄市 COVID-19 疫情的流行病学和动力学特征。

研究首先关注了疫情的流行病学特征，包括时间序列、年龄-性别分布和地理分布。这些因素被纳入分析，以深入了解疫情的传播模式和影响。其次，对微分方程模型的动力学性质进行了研究。模型的性质包括无病平衡点的存在唯一性定理以及这些平衡点的稳定性定理。此外，还探讨了地方病平衡点的存在唯一性定理和稳定性定理。这些理论结果有助于理解疫情传播的基本特征。最后，对神经网络模型的动力学特征进行了考察，包括控制措施开始前的失觉期、疫情中的拐点以及最终规模的预测。这些特征有助于制定有效的防控策略和预测疫情的发展趋势。通过 SEIRV 仓室模型和神经网络模型的结合，以及对流行病学和动力学特征的深入分析，为更好地理解和应对 COVID-19 疫情提供了重要的理论基础和实际支持。

结 论

本文建立了一个 SEIRV 仓室模型，该模型考虑了年龄结构和疫苗接种，并应用于分析 2021 年初石家庄市 COVID-19 疫情的流行病学和动力学特征。

研究首先关注了疫情的流行病学特征，包括时间序列、年龄-性别分布和地理分布。这些因素被纳入分析，以深入了解疫情的传播模式和影响。其次，对微分方程模型的动力学性质进行了研究。模型的性质包括无病平衡点的存在唯一性定理以及这些平衡点的稳定性定理。此外，还探讨了地方病平衡点的存在唯一性定理和稳定性定理。这些理论结果有助于理解疫情传播的基本特征。最后，对神经网络模型的动力学特征进行了考察，包括控制措施开始前的失觉期、疫情中的拐点以及最终规模的预测。这些特征有助于制定有效的防控策略和预测疫情的发展趋势。通过 SEIRV 仓室模型和神经网络模型的结合，以及对流行病学和动力学特征的深入分析，为更好地理解和应对 COVID-19 疫情提供了重要的理论基础和实际支持。

致 谢

深切感谢蒲晓蓉教授带我走近神经网络理论与应用这门课程。

此课程论文中关于微分方程理论和流行病学相关的问题是在我的本科导师魏凤英教授指导下完成的。

衷心感谢我的妻子，在我在电子科技大学的日子里一直陪伴着我。